

Закон Ципфа

Закон Ципфа – это разновидность степенного распределение типа

$$u(x) \sim x^{-(1+\alpha)} \quad (1)$$

с показателем $\alpha > 1$.

Иначе его можно записать следующим образом:

$$\ln(n) + \ln(w_n) = \text{const},$$

где n – ранг слова, w_n – частота встречаемости этого слова. Это так называемый первый закон Ципфа.

Он говорит нам о том, что если все слова языка (или просто достаточно длинного текста) упорядочить по убыванию частоты их использования, то **частота n -го слова w_n в таком списке окажется приблизительно обратно пропорциональной его порядковому номеру n** (так называемому *рангу* этого слова). Например, второе по используемости слово встречается примерно в два раза реже, чем первое, третье — в три раза реже, чем первое, и так далее.

Ципф заметил, что эта формула недостаточно точно отображает частотное распределение, поэтому в последствии ввел поправочный коэффициент:

$$\frac{1}{D} \ln(n) + \ln(w_n) = \text{const}$$

D – нормировочный коэффициент.

Таким образом, закон Ципфа — эмпирическая закономерность распределения частоты слов естественного языка:

Автором открытия закономерности является французский стенографист **Жан-Батист Эсту**, который описал её в 1908 году в работе «Диапазон стенографии». Закон был впервые применён для описания распределения размеров городов немецким физиком Феликсом Ауэрбахом в работе «Закон концентрации населения» в 1913 году и носит имя американского лингвиста Джорджа **Ципфа**, который в 1949 году активно популяризировал данную закономерность, впервые предложив использовать её для описания распределения экономических сил и социального статуса.

В 1999 году экономист Ксавье Габэ описал закон Ципфа как пример степенного закона: если города будут расти случайным образом с одинаковым среднеквадратичным отклонением, то в пределе распределение будет сходиться к закону Ципфа.

Согласно выводам исследователей по отношению к городскому расселению в Российской Федерации, в соответствии с законом Ципфа:

- большинство городов России лежит выше идеальной кривой Ципфа, поэтому ожидаемая тенденция — продолжение сокращения численности и людности средних и малых городов за счёт миграции в крупные города;
- соответственно 7 городов-миллионников (Санкт-Петербург, Новосибирск, Екатеринбург, Нижний Новгород, Казань, Челябинск, Омск), находящиеся ниже идеальной кривой Ципфа, имеют существенный резерв роста населения и ожидают прирост населения;
- существуют риски депопуляции первого города в ранге (Москвы), поскольку второй город (Санкт-Петербург) и последующие крупные города сильно отстают от идеальной кривой Ципфа в связи со снижением спроса на рабочую силу при одновременном росте стоимости проживания, включая, прежде всего, стоимость покупки и аренды жилья.

Формула (1) является теоретической реализацией – степенная функция слишком быстро возрастает при $x \rightarrow 0$, чтобы распределение было нормируемым, и слишком медленно убывает при $x \rightarrow \infty$, чтобы оно имело конечные моменты всех порядков. Поэтому $u(x)$ имеет степенной вид только в области промежуточной асимптотики и должна отклоняться от него как при достаточно малых значениях аргумента, так и при очень больших. Простейшим способом учесть отклонение от степенной зависимости при малых x является распределение Парето.

$$F(x) = \begin{cases} 1 - \left(\frac{x}{x_0}\right)^{-\alpha} & \text{при } x > x_0, \\ 0 & \text{при } x < x_0 \end{cases}$$

где x_0 – эффективный порог мелких событий.

Американский специалист по биоинформатике Вэньтянь Ли предложил статистическое объяснение закона Ципфа, доказав, что случайная последовательность символов также подчиняется этому закону. Автор делает вывод, что закон Ципфа, по-видимому, является чисто **статистическим феноменом**, который не имеет отношения к семантике текста и имеет поверхностное отношение к лингвистике.

В общих чертах доказательство этой теории состоит в следующем. Вероятность случайного появления какого-либо слова длиной n в цепочке случайных символов уменьшается с ростом n в той же пропорции, в какой растёт при этом ранг этого слова в частотном списке (порядковой шкале). Потому произведение ранга слова на его частоту есть константа.

Н-граммы и Коллокации

Н-граммы - просто последовательность из *n* элементов (звуков, слогов, слов или букв). На практике чаще имеют в виду ряд слов (реже — букв). Последовательность из двух последовательных элементов называют **биграмма**, из трёх элементов — **триграмма**.

Например,

мама мыла мылом раму

биграммы: *мама мыла, мыла мылом, мылом раму*

триграммы: *мама мыла мылом, мыла мылом раму*

Коллокацией называется словосочетание, имеющее признаки **синтаксически и семантически целостной единицы**, в котором выбор одного из компонентов осуществляется по смыслу, а выбор второго зависит от выбора первого (например, *ставить условия* — выбор глагола *ставить* определяется традицией и зависит от существительного *условия*, при слове *предложение* будет другой глагол — *вносить*).

К коллокациям также обычно причисляют составные топонимы, антропонимы и другие часто совместно употребляемые именованья (например, *крейсер «Аврора»*, *завод имени Кирова*, *республика Марий Эл*).

Другое наименование того же явления — устойчивые или фразеологические словосочетания, N-граммы, коммуникативная единица.

В отличие от идиом (*подложить свинью*, *темна вода в облаках* и т. п.) коллокации широко распространены, без них невозможно говорить по-русски.

Слово, которое сохраняет своё значение, называется **ключевым**, или **свободным** компонентом: слово *резолуция* в *вносить резолюцию*, слово *смысл* в сочетании *имеет смысл*. Свободный компонент порождается по обычным правилам порождения речи: подбирается по значению в зависимости от выражаемого смысла.

Слово, выбор которого определяется традицией, зависит от ключевого компонента и должен храниться в памяти (в словаре), называется **несвободным** компонентом. Для того, чтобы выбрать правильный глагол при слове *влияние*, необходимо не только представлять, какой смысл нужно выразить (смысл «делать»), но и помнить (или узнать из словаря), что это глагол *оказывать*, а не *делать*, не *производить*, не *создавать*.

Классификация коллокаций

Коллокации по синтаксически главному слову делятся на:

- глагольные (*оказать влияние, внести изменения, идет дождь*);
- именные (*высокая температура, рост влияния*).

Коллокации также могут классифицироваться в зависимости от функционального стиля, в котором они употребляются. Большинство коллокаций — книжные: научные (*вести исследования*), официально-деловые (*выносить приговор*), газетно-публицистические (*энтузиазм охватил*). Но есть и разговорные (*нести ерунду, молоть чушь*).

По лексическому составу коллокации делятся на

- Несоставные
- Незаменяемые
- Неизменяемые

У **несоставных** коллокаций смысл полностью отличается от её составных частей. Это, как правило, идиомы и идиоматические выражения. Например, взрыв смеха, *дать дуба*, *наставить рога* и пр.

Незаменяемые коллокации не допускают синонимическую замену одного слова другим. В этот класс входят устойчивые обороты и метафоры. Например, (для) *красного словца* или *белое вино* нельзя заменить на *прозрачное вино* или *жёлтое вино* и пр.

Неизменяемые коллокации содержат жёсткие связи между словами, не разрешающие их изменять с помощью дополнительной лексики или замены грамматической функции. Например, *дойти до точки* не заменить на *до точка*, *сердце в пятки* не заменить на *сердце в пятку*, а (*ходить*) *вокруг да около* — на (*ходить*) *вокруг дома да около*.

Ещё одна классификация коллокаций — на **разрывные** и **неразрывные**. В разрывные коллокации могут попадать второстепенные слова (*жизнь кипит* и *жизнь его кипит*, *жизнь его постоянно кипит* и пр.).

Коллокации выявляются при лексическом анализе текста. Статистические методы, отмечающие частоту совместного употребления, могут помочь их обнаружить в весьма малой степени. Некоторые статистические методы получения коллокаций:

- Частотные методы (обычно используются с частеречевым фильтром англ. POS-filter).
- Подсчёт среднего значения и дисперсии (для поиска разрывных коллокаций).
- C-value — показывает устойчивость коллокаций.
- Методы, основанные на теореме Байеса.
- Т-критерий (или критерий Стьюдента).
- Критерий Хи-квадрат.
- Метод отношения правдоподобия.
- Коэффициент Джаккара
- Метод Дайса.
- Взаимная информация (MI & PMI).

Мера Дайса

Мера Сёренсена — бинарная мера сходства, предложенная датским учёным Торвальдом Сёренсеном в 1948 году

$$K_{0,-1} = \frac{2n(A \cap B)}{n(A) + n(B)}$$

Если сравнивается встречаемость видов (вероятностная интерпретация), то есть учитываются вероятности встреч признаков, то аналогом меры Сёренсена будет симметричная мера **Дайса**

$$K_{0,-1} = \frac{2P(A \cap B)}{P(A) + P(B)}$$

Коэффициент Дайса измеряет, насколько похожи одна последовательность на другую. Его можно использовать для измерения сходства двух строк относительно общих n-грамм.

Взаимная информация (MI – Mutual Information)

Взаимная информация - статистическая функция двух случайных величин, описывающая количество информации, содержащееся в одной случайной величине относительно другой.

Взаимная информация определяется через энтропию и условную энтропию двух случайных величин как

$$I(X; Y) = H(X) - H(X | Y) = H(X) + H(Y) - H(X, Y)$$

$$= H(X) - H(X|Y) = H(Y) - H(Y|X)$$

Энтропия - мера хаоса или неопределенности (чем меньше элементы системы подчинены какому-либо порядку, тем выше энтропия). В теории информации выражается через математическое ожидание собственной информации:

$$H(X) = E(I(X)) = - \sum_{i=1}^n p(i) \log p(i).$$

Примечание: математическое ожидание — одно из важнейших понятий в теории вероятностей, означающее среднее (взвешенное по вероятностям возможных значений) значение случайной величины.

Условная энтропия определяет количество остающейся энтропии (то есть, остающейся неопределенности) события **Y** после того, как становится известным результат события **X**. Иначе говоря, это математическое ожидание условной вероятности события **Y** при свершившемся **X**:

$$H(Y|X) = E(-\log P(Y|X))$$

где $P(X|Y) = P(X, Y) / (P(X) * P(Y))$

Перепишем формулу взаимной информации в терминах вероятности:

$$I(X; Y) = \sum_{y \in Y} \sum_{x \in X} p(x, y) \log \left(\frac{p(x, y)}{p(x) p(y)} \right),$$

PMI — pointwise mutual information, поточечная взаимная информация. Она относится к отдельным событиям, тогда как MI относится к среднему значению всех возможных событий.

$$PMI(A, B) = \log \frac{P(A \& B)}{P(A) * P(B)} = \log \frac{P(A \text{ near } B)}{P(A) * P(B)}$$

В приведенной выше формуле **A** и **B** — слова (биграммы/н-граммы), **P(A)**, **P(B)** — априорные вероятности появления термина **A** и **B** соответственно в обучающей выборке (отношение количества вхождений к общему количеству слов в корпусе), **P(A near B)** — вероятность термина **A** встретиться вместе/рядом с термином **B**; «рядом» можно конфигурировать вручную, по умолчанию расстояние равно 10 терминам влево и вправо; основание логарифма не играет роли, для простоты примем его равным 2.

Позитивный знак логарифма будет означать положительны окрас **A** по сравнению с **B**, негативный — отрицательный.

C-value

$$C\text{-Value}(t) = \begin{cases} \log_2 |t| \cdot f(t), & \text{если } \{s : t \subset s\} = \emptyset; \\ \log_2 |t| \cdot \left(f(t) - \frac{\sum_s f(s)}{|\{s : t \subset s\}|} \right), & \text{иначе, } \{s : t \subset s\} \neq \emptyset \end{cases}$$

где t – кандидат в термины; $|t|$ – длина кандидата t (в словах); $f(t)$ – частота вхождений t в коллекции текстов; s – множество кандидатов, окружающих кандидата t , т. е. таких кандидатов, что t является их подстрокой. Важно отметить, что мера C-Value предназначена для извлечения только многословных терминов: иначе выражение под логарифмом обнуляет значение признака